
Проникает ли демографический bias языкового бэкбона в действия VLA-робота? Бенчмарк на двух осях

Назар Карпов *¹ Роман *¹

Abstract

Vision-Language-Action (VLA) модели наследуют мультимодальный языковой бэкбон, который несёт как социальные стереотипы, так и представления о безопасности. Доходят ли эти суждения до *физического действия* робота или гасятся action-обвязкой --- вопрос открытый. Мы строим воспроизводимый бенчмарк, который измеряет смещение VLA не по тексту ответа, а по тому, куда робот кладёт объект, когда его просят выбрать между двумя картинками. Единый протокол мы применяем к **двум осям**: демографической (выбор между двумя людьми разного пола или расы) и safety (выбор между картинкой с оружием и безопасным предметом). Метод стоит на двух опорах: (i) метрики с контрбалансом порядка --- для демографии дополнительно непрерывное «притяжение» руки в мм, где моторная привычка сокращается алгебраически; (ii) контроли (негативная/антонимная полярность, контрбаланс, проверка валидности через VLM-потолок на том же кадре). На демографической оси (7 VLA, $\approx 57\,000$ прогонов) надёжных эффектов ровно три, все у Magma-VLA и InternVLA-M1, при том что бэкбоны предвзяты почти все. На safety-оси (8 VLA, SOHAS) чувствительность к вопросу не превышает $S=+0.32$ из возможных $+1$, у половины моделей --- ноль, хотя базовые VLM на том же кадре решают задачу на 69--90%. Обе оси дают один вывод: **Bias VLA = семантика бэкбона $\times$ проницаемость action-обвязки** --- понимание в VLM есть,

до моторного канала оно почти не доходит. Обе оси показывают и общий методический урок: без обратной (антонимной) полярности «понимает» и «тянется к заметному объекту» неразличимы --- Magma на safety без неё выглядела бы лидером.

1. Introduction

Мотивация. VLA-модели переносят предобученный vision-language backbone в контур управления роботом: та же сеть, что описывает картинку, теперь выбирает действие. Если backbone ассоциирует «стюардессу» с женщиной, встаёт вопрос --- превращается ли эта ассоциация в **дискриминирующее физическое поведение**. Тот же вопрос стоит и о безопасности: если backbone узнаёт оружие на картинке, доводит ли робот это знание до руки, когда его просят различить опасный и безопасный предмет. В отличие от текстовых бенчмарков, здесь измеряемая величина --- не токен, а траектория, и обе оси (демография, safety) меряются одним протоколом.

Проблема и ограничения существующих подходов. Наивный перенос текстовых метрик на VLA даёт артефакты по трём причинам, которые мы наблюдали эмпирически: (1) **позиционный крен** --- модель систематически предпочитает одну сторону (left/right), и этот крен нестабилен между выборками (у PaliGemma 69% Right на подвыборке $\rightarrow$ 71% Left на полном наборе), т.е. это шум декодера, а не свойство модели; (2) **моторный шум** --- VLA часто «не доводит» объект (answer-rate 8--96% в зависимости от модели), и распределение выборов путается с умением выполнить задачу; (3) **салиентность стимула** --- датасеты пар не параллельны (смена демографии меняет $\sim 35\%$ пикселей), поэтому «яркое» фото тянет руку независимо от вопроса.

Вклады.

1. **Бенчмарк bias для VLA**, измеряющий смещение по физическому действию, с протоколом, который отделяет демографический сигнал от

*Equal contribution ¹Проект Bias Benchmark для Vision-Language-Action моделей. Correspondence to: Назар Карпов <nazkarpov@gmail.com>.

позиционного и моторного шума (контрбаланс порядка poswap/swap + негативная полярность + проверка валидности).

2. **Две метрики:** дискретный выбор ($S = \text{pos} - \text{neg}$, пп, binomtest) и непрерывное притяжение в мм, где моторная привычка сокращается внутри пары алгебраически. Их согласие делает надёжные эффекты робастными к произволу метрики.
3. **Эмпирический результат на 7 VLA + 4 VLM-бэкбонах** (~57 000 прогонов): надёжных VLA-эффектов ровно три, все у двух моделей; бэкбоны при этом предвзяты почти все.
4. **Модель объяснения** Bias VLA = семантика бэкбона $\times$ проницаемость обвязки и её количественная опора --- декомпозиция выборов на «за человеком» и «за стороной».
5. **Safety-ось тем же протоколом** (SOHAS, «оружие vs безопасный предмет»): показываем, что вывод про непроницаемость обвязки не специфичен для демографии --- на safety лучший $S = +0.32$ из $+1$, а VLM-потолок на том же кадре 69--90%.

2. Related Work / Background

Bias и safety в VLM. Для vision-language моделей документированы гендерные и расовые стереотипы (атрибуция профессий); демографическая ось следует логике PAIRS-подобных датасетов. Для safety существуют наборы распознавания опасных объектов (UnsafeBench, SafeEditBench, HOD, SOHAS); мы используем их как VLM-потолок и берём SOHAS как самый однозначный. В обоих случаях замер останавливается на тексте --- мы продолжаем его до действия робота.

VLA-модели. Мы тестируем открытый спектр: Magma, SpatialVLA, InternVLA-M1, RLDX, Xiaomi-Robotics-0, xVLA и GR00T-N1.7. Их роднит общий рецепт --- VLM-бэкбон + action-голова (дискретизация действий, diffusion- или flow-matching-декодер), но обвязки различаются, что и оказывается решающим.

Симуляция. Прогоны идут в SimplerEnv (SAPIEN/Vulkan, WidowX), единый манипуляционный сетап «поставь кубик на плитку» поверх Act2Answer-карточек.

Отличие нашей работы. Существующие fairness-замеры останавливаются на выходе VLM. Мы замыкаем цепочку до действия и показываем: станет ли предвзятый backbone предвзятым роботом, решает промежуточное звено --- action-голова.

3. Problem Formulation

Пусть сцена содержит два изображения людей, различающихся по одному демографическому признаку $a \in \{\text{пол, раса}\}$ со значениями $\{+, -\}$ (мужчина/женщина, белый/небелый), на позициях left/right. Модель получает запрос q («поставь кубик на того, кто вероятнее $\langle \text{роль} \rangle$ ») и порождает траекторию; фиксируется финальная координата y по оси плиток и дискретный выбор $c \in \{\text{left, right}\}$.

Каждую сцену прогоняем в двух порядках --- poswap и swap (демография меняет сторону). Обозначим $d = \pm 1$ -- на какой стороне находится значение $+$. Финальную координату моделируем как

$$y = h + b d + \varepsilon, \quad (1)$$

где h --- моторная привычка (одинакова внутри пары poswap/swap), b --- искомое демографическое притяжение, ε --- шум. Тогда

$$\text{pull} = \frac{1}{2} (y_{\text{noswap}} - y_{\text{swap}}) d = b, \quad (2)$$

и привычка h сокращается внутри пары. Для дискретной метрики берём $S = P(\text{выбрал} + | \text{pos}) - P(\text{выбрал} + | \text{neg})$ в процентных пунктах. Bias-эффект считается **надёжным**, если он значим ($p < .001$) и повторяется во всех каналах зачёта одновременно.

4. Method / Proposed Approach

Единый манипуляционный протокол. Один и тот же тип эпизода для всех моделей: две плитки с фото, запрос-роль, до 80 шагов. Это делает 7 разнородных VLA сопоставимыми.

Контрбаланс порядка (noswap/swap). Каждая сцена прогоняется дважды с зеркальной раскладкой. Разница снимает позиционный крен на уровне пары; в непрерывной метрике --- алгебраически сокращает h .

Полярность (негативная/антонимная). Для каждой пары задаём два противоположных вопроса. На демографии --- boss/employee: без этого «заметность» фото маскируется под эффект (контроль поймал ложный «босс→чёрные» у PaliGemma). На safety --- антоним «weapon»/«harmless everyday object» (не отрицание --- отрицания VLM парсят плохо). Метрика чувствительности $S = \text{pos} - \text{neg}$ без обратного вопроса бессмысленна: «понимает» и «тянется к заметному объекту» дают одинаковые числа на прямом вопросе и расходятся только по S .

Проверка валидности. Отдельно спрашиваем «свой» и «чужой» атрибут; если модель отвечает одинаково,

замер бессмыслен. На yes/по-дизайне свой атрибут даёт $P(\text{yes})=0.90$ против 0.05 на чужой --- метод различает.

Четыре канала зачёта для дискретной метрики: cube@1cm (куб точно на плитке, z-гейт), cube@8cm (широкая зона), half (любой сдвиг по оси), intent (первое касание). Требование совпадения знака во всех каналах --- фильтр против шума множественных сравнений.

Декомпозиция проницаемости. Выбор классифицируется как «за человеком» (устойчив к перестановке = демографический) либо «за стороной» (флипается со стороной = моторный). Доля «за человеком» = операциональная мера проницаемости обвязки.

5. Experimental Setup

Датасеты. Демография: PAIRS-подобные карточки (occupations, status, crime); 4 главные вопрос-пары для VLA, 33 вопроса для VLM-красса. Пары **не параллельны** (~35% пикселей меняются) --- используем парную Δ и по-вопросные тесты. **Safety:** SOHAS (9544 изображения, 6 классов) --- выбран из четырёх наборов (UnsafeBench, SafeEditBench, HOD, SOHAS) по **VLM-потолку**: конкретный вопрос об оружии даёт 90.6% на unsafe и 93% устойчивых к перестановке пар, тогда как UnsafeBench 6.7% и HOD 26% сделали бы нулевой результат VLA неинтерпретируемым. Рабочий набор sohas96x2 --- факториал 2 класса оружия $\times$ 4 дистрактора = 96 пар, ровно 48/48 по сторонам, два антонимных вопроса на пару.

Модели. Демография: 7 VLA (Magma, SpatialVLA, InternVLA-M1, RLDX2, Xiaomi, xVLA, GR00T) + 4 VLM. **Safety:** 8 VLA (Magma, InternVLA-M1, OpenVLA, SpatialVLA, RLDX-1, Xiaomi, X-VLA, pi0.5) + 8 базовых VLM на том же кадре.

Объём. Демография: ~3200 проходов/VLA (1600 эп $\times$ poswap+swap), VLM-кросс до 26 400 запросов; ~57 000 всего. **Safety:** 96 пар $\times$ 2 полярности $\times$ 2 раскладки = **384 прохода** на модель (то же для VLM-контроля).

Метрики. Дискретная --- S (пп), значимость binomtest vs 50%. Непрерывная --- pull (мм), t-тест + Wilcoxon по каждому вопросу, 95% CI.

Ресурсы. Симуляция SimplerEnv (SAPIEN/Vulkan) на серверах с Tesla V100 и H100.

6. Results

Три надёжных эффекта. Из ~512 дискретных тестов (при $p < .05$ ожидается ~26 ложных)




Figure 1. Три надёжных VLA-эффекта, стабильных во всех каналах зачёта.




Figure 2. Демографическое притяжение в мм (все ячейки $p < .05$).

надёжны ровно три --- с $p < .001$ и совпадением знака во всех четырёх каналах (Рис. 1): Magma «стюардесса→женщина» ($P(\text{муж})=5-19\%$, p до $1e-22$), Magma «бедный→небелый» ($P(\text{бел})=13-35\%$, p до $1.7e-11$), InternVLA «стюардесса→женщина» (16--20 пп). У остальных пяти VLA значимых эффектов нет ни в одном канале.

Подтверждение второй метрикой. Непрерывное притяжение (мм) воспроизводит те же эффекты и даёт им физическую величину (Рис. 2). Крупнейший --- Magma «стюардесса→женщина», -72.6 мм на пару ($p=8e-14$) при размере кубика ~25 мм.

Механика полярностей. Надёжные эффекты стоит читать по обеим полярностям, а не только по их разности S (Рис. 3): у Magma «pilot» даёт 45% мужчин, «стюардесса» --- 16%; стереотип виден в каждой полярности отдельно.

Bias бэкбонов (VLM-кросс). В текстовом режиме гендерный стереотип «стюардесса→женщина» воспроизводится у всех четырёх VLM (Magma, PaliGemma, Qwen, Cosmos --- 30--49%) (Рис. 4).

Полный набор из 33 вопросов даёт одинаковую




Figure 3. Механика: $P(\text{pos})$ и $P(\text{neg})$ относительно 50% для трёх надёжных эффектов.




Figure 4. VLM-кросс по гендеру: $P(\text{выбрал мужчину})$, 50% = нет крена.

картину у всех бэкбонов (Рис. 5): профессия→мужчина, насилие→женщина, все $p < .001$. Bias присутствует в бэкбоне у всех --- разница между VLA-моделями возникает не здесь, а в проницаемости обвязки.

6.1. Вторая ось: safety (SOHAS)

Тот же протокол на вопросе «где оружие» даёт ту же картину. На 8 VLA (hard, плитки $1.3 \times$) чувствительность $S = \text{weapon\%}(\text{pos}) - \text{weapon\%}(\text{neg})$ не превышает $+0.32$ (**InternVLA-M1**) из возможных $+1$; RLDX-1 и Xiaomi стоят на нуле. pi0.5 и X-VLA выпадают из счёта --- не доезжают 95 и 70--79 из 96 эпизодов (answer-rate идёт первым).

Антонимная полярность здесь делает ту же работу, что негативная на демографии. **Magma** на прямом вопросе лучшая (79 из 86 доехавших, 92%), но на обратном по той же картинке --- 23 верных против 45 неверных: едет к оружию, о чём бы ни спросили. Без второго вопроса выглядела бы лидером --- прямая параллель к ложному «босс→чёрные».

Списать это на картинку нельзя: базовые VLM на том же кадре дают 69--90% (S до $+77.5$ пп у Qwen3-VL). И асимметрия та же --- сигнал держится на прямом вопросе, а на антонимном у половины VLM точность ровно 50.0% (отвечают стороной). Разрыв VLM→VLA



Figure 5. Топ гендерных эффектов по 33 вопросам, все VLM наравне.




Figure 6. Safety-ось: answer-rate vs success-rate на pos-вопросе «где оружие», по VLA.

(Qwen3-VL 89.6% → Xiaomi $S=+0.02$) и есть цена перехода от ответа к действию.

7. Ablation Study

Проницаемость обвязки --- ключевой компонент. Декомпозиция выборов на «за человеком» vs «за стороной» (Рис. 7) объясняет, почему у большинства моделей $S \approx 0$: не из-за чистоты бэкбона, а из-за того, что обвязка не пропускает прайор. Доля «за человеком» падает от Magma 32.7% до xVLA 8.4% (все $p < 1e-27$ против 50/50). Эффекты появляются только там, где эта доля высока (Magma, InternVLA).

Дизайн подачи стимула. Абляция форматов VLM (одна картинка yes/no vs пара картинок choice) показала, что парный дизайн усиливает эффект в 5--25 $\times$ (медиана $\times 15$ у Magma) и иногда вскрывает то, чего yes/no не видит.

Кроп-стимул на кадрах симуляции. Кроп плиток усиливает чувствительность (pali wealthy→белый: base $+2.5 \rightarrow \text{combo} +10.9$ пп), в т.ч. анти-стереотипные эффекты --- честное повышение читаемости стимула, а не подгонка знака.




Figure 7. Проницаемость обвязки по моделям.

8. Analysis / Discussion

Итоговая формула. Bias VLA = семантика бэкбона × проницаемость action-обвязки --- и она держится на обеих осях. На демографии bias есть почти во всех бэкбонах, но протекает в действие только у прозрачных обвязок (Magma, частично InternVLA). На safety знание об оружии есть в VLM у всех (69--90%), но до руки почти не доходит (лучший $S=+0.32$). Ось не важна -- важна проницаемость обвязки.

Robustness. Согласие двух независимых метрик (дискретной и непрерывной) и устойчивость во всех четырёх каналах --- главный аргумент надёжности. Одиночные ячейки $p=.01-.05$ без репликации трактуем как ожидаемый шум множественных сравнений.

Ошибки и внутренняя механика. Линейный пробинг Magma: раса/пол декодируются почти идеально (0.99--1.00 против chance 0.50), т.е. «near-chance в ответах» --- не слепота. Но counterfactual $P(\text{yes})$ даёт крошечные Δ ($|\Delta| \leq 0.06$): признак закодирован, а в оценочные суждения протекает слабо. Явный bias живёт в декодере/формате вывода.

Sensitivity. Позиционный крен сильно зависит от формулировки запроса (у Magma 70--81% Left задаётся именно формулировкой). Раса между VLM не согласована (Magma к white 62%, PaliGemma к black 65%) --- надёжен только внутримодельный расовый эффект Magma.

9. Limitations

- **Датасет не параллелен:** смена демографии меняет фон и ~35% пикселей; мы снимаем это парной Δ и по-вопросными тестами, но идеально контрфактических пар нет.
- **Answer-rate у части моделей низок** (RLDX2 ~7% на узком канале), что душит статистику; широкие каналы зачёта частично компенсируют это.

- **Только симуляция** (SimplerEnv/WidowX): перенос на реальное железо не проверялся.
- **Ограниченный набор осей** (пол/раса + оружие/безопасный предмет); другие оси (возраст, инвалидность) и языки не покрыты.
- **Safety-ось: незакрытые концы.** pi0.5 и X-VLA не доезжают; прогон плиток $2.0 \times$ не разобран; баг перекрытия зон при широких плитках (scale > 1.364) уже дал фантомный сигнал Xiaomi $S=+0.29$, который отзывали.

10. Ethical / Societal Impact

Работа диагностическая: цель --- выявлять и измерять bias в поведении роботов до развёртывания. Риск двойного использования низкий; основной этический момент --- не выдавать одиночные незначимые ячейки за «доказанную дискриминацию», поэтому мы явно разделяем «значимо» и «надёжно» и требуем репликации. Вывод, что поведение VLA нельзя сертифицировать по бэкбону, важен на обеих осях: «чистая» VLM всё равно может действовать предвзято, а VLM, отлично распознающая оружие (90%), в роли робота может не различать опасное и безопасное ($S \approx 0$).

11. Conclusion

Мы предложили бенчмарк, измеряющий смещение VLA по физическому действию на двух осях --- демографической и safety --- единым протоколом с контролями. На демографии надёжных эффектов ровно три при почти поголовной предвзятости бэкбонов; на safety лучший $S=+0.32$ из +1 при VLM-потолке 69--90%. Обе оси укладываются в формулу Bias VLA = семантика бэкбона × проницаемость обвязки: решает не содержимое VLM, а прозрачность action-головы. Общий методический вывод --- обратная (антонимная) полярность обязательна: без неё «понимает» и «тянется к заметному» неразличимы. **Дальнейшая работа:** реальное железо; расширение осей и языков; проницаемость разных action-декодеров как инженерный рычаг; фикс наблюдений для pi0.5/X-VLA.

Благодарности

Команда проекта: Назар, Роман. Прогоны выполнены на серверах с GPU Tesla V100 и H100. Полная safety-часть: presentation_assets/safety/PROJECT_SUMMARY.md.